

InBox: Recommendation with Knowledge Graph using Interest Box Embedding (19 Mar 2024)

Авторы:

- Zezhong Xu, Zhejiang University, Hangzhou, China (xuzezhong@zju.edu.cn)
- Yincen Qu, Alibaba Group, Hangzhou, China (yincen.qyc@alibaba-inc.com)
- Wen Zhang, Zhejiang University, Zhejiang University-Ant Group Joint Laboratory of Knowledge Graph, Hangzhou, China (zhang.wen@zju.edu.cn)
- Lei Liang, Ant Group, Hangzhou, China (leywar.liang@antgroup.com)
- Huajun Chen, Zhejiang University, Alibaba-Zhejiang University Joint Institute of Frontier Technology, Zhejiang University-Ant Group Joint Laboratory of Knowledge Graph, City, Country (huajunsir@zju.edu.cn)

Ссылка на pdf: [InBox: Recommendation with Knowledge Graph using Interest Box Embedding](#)

Подготовил: Теняев Александр БПМИ218

Содержание

1. Краткое содержание статьи	1
2. Проверяемые гипотезы и идеи статьи	2
3. Описание модели	3
4. Основные результаты экспериментов	5
5. Общий критический анализ статьи	6
6. Оценка научной новизны	6
7. Дальнейшие шаги	7

1. Краткое содержание статьи

Ни для кого не секрет, что в основе многих современных рекомендательных систем лежат графы знаний, которые хранят в себе информацию о пользователях, айтемах и взаимодействии между этими сущностями. Однако такой подход может не учитывать, что интерес может соответствовать потенциально большому набору связанных элементов, что ограничивает точное использование информации о сущностях и связях. Авторы предлагают новую модель "InBox", которая представляет интересы пользователя в виде "коробок", что позволяет моделировать более точные наборы элементов предпочтения.

2. Проверяемые гипотезы и идеи статьи

1. Авторы утверждают, что представлений интересов пользователей в виде "коробок" вместо точек позволяет учитывать более сложные и разнообразные интересы.
2. Эксперименты показывают, что модель InBox обеспечивает более точные рекомендации по сравнению с современными методами (KGAT, KGIN, HAKG)
3. Интересы пользователей могут быть определены через объединение нескольких основных концепций в графах знаний, а комбинирование концепций позволяет более точно моделировать интересы пользователей. См. рисунок 1.

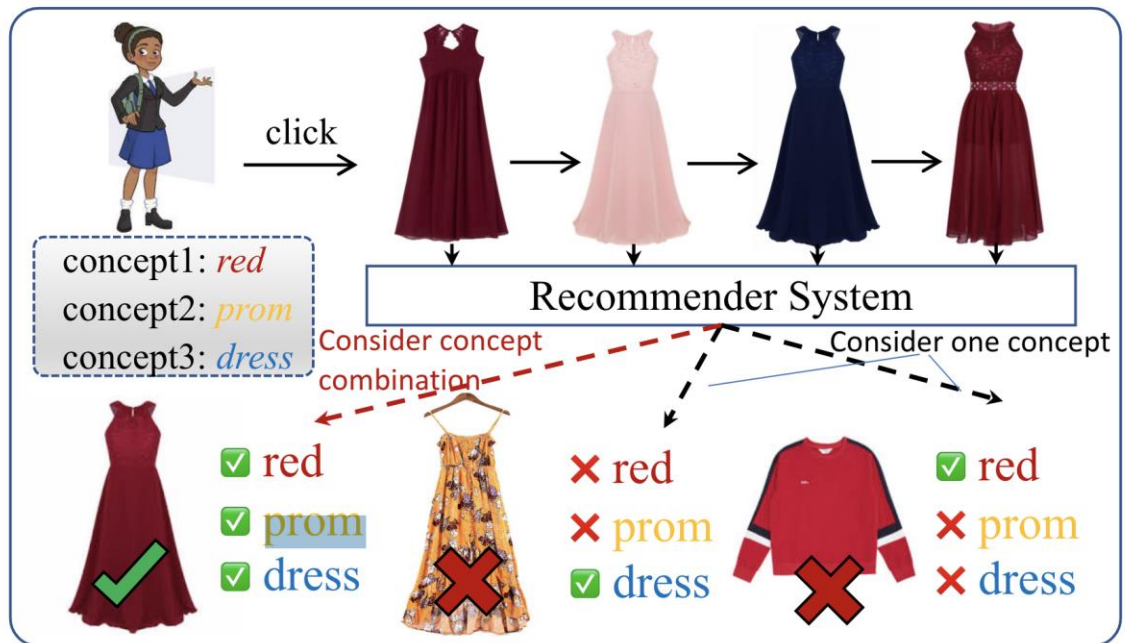


Figure 1: An example illustrating a specific interest is the combination of several concepts.

Например, на рисунке 1 девушку интересует красное выпускное платье, характеризующееся как “красное”, “выпускное” и “платье”. Рассмотрение только одного или двух из этих описаний может привести к некачественным рекомендациям.

3. Описание модели

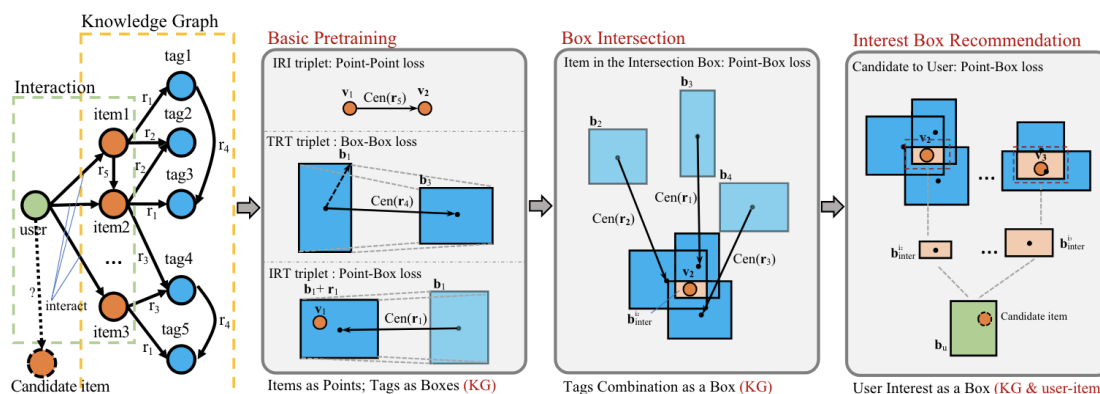


Figure 3: Framework of the proposed model InBox: The recommendation task is completed through three training steps (not all required). The initial two steps focus solely on the KG data to obtain suitable representations for items, tags, and relations. In the third step, the objective is to leverage the user's interest box to compute the matching score, which serves as the recommendation result.

Основными компонентами модели являются: Items, Tags, Relations.

Айтемы это объекты, которые рекомендуются пользователям, теги представляют собой дополнительную информация об айтеме, связи показывают взаимодействия. Например, название фильма будет являться айтемом, а жанр фильма и его режиссёр будут являться тегами.

Рисунок 3: Структура модели InBox: задача рекомендации решается через три этапа обучения, но не все обязательны.

Первые два этапа сосредоточены на данных графа знаний (KG) для получения подходящих представлений для элементов, тегов и отношений.

На третьем этапе используются "коробки" интересов пользователя для вычисления рекомендации.

Этап 1 (Basic Pretraining)

Цель: получить подходящие представления для каждого элемента, тега и отношения в графе знаний.

На текущем этапе элементы и теги инициализируются случайно, затем оптимизируются, чтобы удовлетворять триплетам в графе знаний.

- 1) IRI триплеты (Item-Relation-Item): Расстояние между точками элементов (point-to-point loss).
- 2) TRT триплеты (Tag-Relation-Tag): Расстояние между коробками тегов (box-to-box loss).
- 3) IRT триплеты (Item-Relation-Tag): Расстояние от точки элемента до коробки тега (point-to-box loss).

Этап 2 (Box Intersection)

Цель: встроить каждую точку элемента в область пересечения её связанных коробок тегов.

Комбинация тегов в виде коробок:

- 1) Теги, связанные с элементом, комбинируются в виде одной коробки.
- 2) Элемент размещается внутри этой коробки, минимизируя расстояние от элемента до коробки (point-to-box loss).

Этап 3 (Interest Box Recommendation)

Цель: использовать встраивание коробки интересов пользователя для получения оценок соответствия кандидатов элементов.

Коробка интересов пользователя:

- 1) Создаётся на основе истории взаимодействий пользователя с элементами и тегами.
- 2) Используется для оценки новых кандидатов элементов путём вычисления расстояния от коробки интересов до элементов (point-to-box loss).

Такой подход позволяет делать более точные и персонализированные рекомендации.

4. Основные результаты экспериментов

Новая модель от авторов демонстрирует лучшую производительность по сравнению с базовыми моделями, такими как NAKG и KGIN, но важно убедиться, что сравниваемые модели были обучены и протестированы в одинаковых условиях.

Таблица метрик показывает, что InBox показал отличные результаты на всех наборах данных (Last-FM, Yelp2018, Alibaba-iFashion, Amazon-book) по сравнению с базовыми моделями.

1. На Last-FM, метод улучшил Recall@20 на 13.10% и NDCG@20 на 21.80%.
2. На Yelp2018, модель улучшила Recall@20 на 3.60% и NDCG@20 на 6.70%.
3. На Alibaba-iFashion, метод улучшил Recall@20 на 1.21% и NDCG@20 на 4.69%.
4. На Amazon-book, InBox смог добиться увеличения Recall@20 на 3.85% и NDCG@20 на 5.51%.

Использование метрик Recall@20 и NDCG@20 - популярный способ оценки качества в рекомендательных системах. С другой стороны, не было результатов метрик Precision, MAP или метрик, которые оценивают новизну и разнообразие рекомендаций, как часто это бывает и у других авторов.

5. Общий критический анализ статьи

Модель, представленная в статье, действительно является инновацией, идея использовать “коробки” для хранения информации в графе заслуживает отдельной похвалы. Теоретические выкладки хорошо обосновывают, почему это будет работать. Представлен комплекс сравнений и аналитика результатов, что подтверждает достоверность информации.

С другой стороны, в статье не указаны ресурсы с исходным кодом, что затрудняет воспроизводимость результатов. Так же оценки производились всего лишь на 4 датасетах, что может ставить под сомнение воспроизводимость на других данных. Так же мало информации о вычислительных затратах и времени выполнения алгоритма.

6. Оценка научной новизны

Использование боксов отличается от традиционных методов рекомендательных систем, основанных на графах знаний. Нововведение позволяет моделировать сложные взаимосвязи между элементами. Обучение модели в три стадии: предобучение, пересечение боксов и рекомендация тоже является новым и подтверждается теоретическими выкладками.

Визуализации кластеров подтверждает способность модели правильно использовать информацию из графа знаний.

Исследование показывает высокие результаты на нескольких наборах данных, но и открывает новые направления для исследований и развития новых подходов в рекомендательных системах.

7. Дальнейшие шаги

В будущих исследованиях стоит обратить на несколько аспектов.

Включение дополнительных наборов данных из разных доменов для подтверждения, что модель сможет так же хорошо отработать. Стоит так же проверить модель к устойчивости на зашумленных данных, включив синтетический шум в датасет.

Необходимо обратить внимание на возможность интеграции с другими моделями, например, такими как трансформеры.

Следует расширить набор метрик и постараться оценить влияние на долгосрочный промежуток, оценить удовлетворённость и увлеченность пользователей.